

Riduzione Dimensionalità

■ Introduzione

- Definizioni
- Le Principali Tecniche
- PCA vs LDA

■ Principal Component Analysis (PCA)

■ Linear Discriminant Analysis (LDA)

■ Riduzione di Dimensionalità per Visualizzazione (2D o 3D)

- t-SNE
- UMAP

Definizioni

Obiettivo dei metodi per la riduzione di dimensionalità (*dimensionality reduction*) è quello di eseguire un **mapping** dallo spazio iniziale $\mathcal{R}^d$ a uno spazio di dimensione inferiore $\mathcal{R}^k$, $k < d$.

Può essere vista come una forma di compressione (con perdita di informazione). Obiettivo è **scartare le informazioni** non rilevanti o meno rilevanti per il problema di interesse:

- ① ■ ^{riduce} ~~allevia~~ i problemi collegati alla curse of dimensionality: operare in spazi ad elevata dimensionalità, a causa del fatto che i pattern sono molto sparsi, richiede ingenti moli di dati per l'addestramento. la Curse of Dimensionality è il fenomeno per cui, all'aumentare del numero di dimensioni, i dati diventano talmente sparsi che gli algoritmi di machine learning perdono efficacia.
- operare in spazi a dimensionalità inferiore rende più semplice addestrare algoritmi di machine learning. ② Scartando dati **ridondanti** (informazioni correlate) e **rumorosi** talvolta si migliorano anche le prestazioni.

Attenzione: riduzione di dimensionalità non significa mantenere alcune «dimensioni» e cancellarne altre, ma «**combinare**» le dimensioni in modo opportuno.

Si tratta invece di combinare (linearmente o non-linearmente) le 'd' dimensioni iniziali per creare le nuove 'k' dimensioni.

Le principali tecniche

Le più note tecniche di riduzione di dimensionalità (che vedremo) sono:

- **Principal Component Analysis (PCA)**: trasformazione ^{lineare e} non-supervisionata nota anche come Karhunen Loeve (KL) transform. Esegue un mapping lineare con l'obiettivo di preservare al massimo l'informazione dei pattern.
- **Linear Discriminant Analysis (LDA)**: il mapping è ancora lineare, ma in questo caso è supervisionato. Mentre PCA privilegia le dimensioni che rappresentano al meglio i pattern, LDA privilegia le dimensioni che discriminano al meglio i pattern del TS.
- **t-distributed Stochastic Neighbor Embedding (t-SNE)**: trasformazione non lineare e non supervisionata, specificatamente ideata per ridurre dimensionalità a 2 o 3 dimensioni ^{per} ~~tra di loro~~ poter visualizzare dati multidimensionali.

Trasformazione molto complicata, richiede addestramento iterativo basato sul gradiente.

Altre tecniche di interesse: (citare solamente)

- **Independent Component Analysis (ICA)**: trasformazione lineare orientata a proiettare i pattern su componenti statisticamente ^{tra di loro} indipendenti anche se non ortogonali (come in PCA e LDA). Considera statistiche oltre al secondo ordine (PCA si limita al secondo ordine).
- **Kernel PCA**: simile a PCA ma più potente perché il mapping è non-lineare. Utilizza un «trucco» simile a quello che permette di passare da SVM lineare a SVM non lineare.
- **Local Linear Embedding (LLE)**: trasformazione non-lineare che invece di calcolare un mapping «globale», considera relazioni tra gruppi di pattern vicini.

Invece di gestire tutto lo spazio in maniera omogenea, si vanno a vedere regioni dello spazio localizzate dove per ciascuna di esse si cerca una mappatura che può essere anche diversa dalle altre regioni

Esempio PCA vs LDA

1. Principal Component Analysis (PCA) - La Soluzione Nera

Mapping: Proiezione su "Eigenvector a1 (PCA)"

Obiettivo: Massimizzare la varianza globale dei dati proiettati. La PCA non è a conoscenza delle etichette (è non supervisionata).

Cosa rappresenta: L'iperpiano nero è l'asse che meglio cattura la dispersione totale dei dati (rossi e blu combinati). Se proiettassimo tutti i punti su questa retta, la distanza tra i punti proiettati sarebbe massimizzata.

Osservazione nel grafico: La retta nera segue l'andamento generale e allungato (l'asse principale di variazione) di tutto il cloud di punti, ignorando il confine tra rosso e blu.

In figura due esempi di riduzione di dimensionalità da $d = 2$ a $k = 1$ dimensione: (vogliamo arrivare a rappresentare un pattern bidimensionale su una retta) ➔

Riduzione cosa significa in questo esempio?

Trovare una retta sulla quale proiettando i pattern massimizziamo l'obiettivo di PCA o LDA

■ Il segmento nero che identifica la **soluzione PCA** è l'iperpiano sul quale proiettando i pattern (indipendentemente dalla loro classe) conserviamo al massimo l'informazione. ➔ Quindi, preserva le distanze originali in quella ridotta

■ Il segmento verde che identifica la **soluzione LDA** è l'iperpiano sul quale proiettando i pattern siamo in grado di distinguere al meglio le due classi (pattern rossi contro blu).

Entrambi sono mapping lineari $\mathbb{R}^2 \rightarrow \mathbb{R}^1$ ma la soluzione (retta) è profondamente diversa.

2. Linear Discriminant Analysis (LDA)


- Mapping: Proiezione su "Vector w (LDA)"

- Obiettivo: Massimizzare la varianza tra le classi e minimizzare la varianza all'interno delle classi.

- Cosa rappresenta: L'iperpiano verde è la direzione che, se utilizzata per proiettare i punti, rende le due classi più distinte e separate possibile nello spazio unidimensionale di arrivo.

- Osservazione nel grafico: La direzione verde è quasi perpendicolare alla direzione del cloud di punti. Questo perché punta verso l'asse che, una volta proiettati i dati, fa in modo che i punti rossi e punti blu siano il più distanti possibile.

PCA è per la compressione (mantenere l'informazione generale), mentre LDA è per la classificazione (mantenere l'informazione di separazione di classe).



Cosa è una proiezione? Se su questa retta mi definisco un'origine, la distanza di un punto dall'origine sarà il suo valore, quindi proiettare significa fare una proiezione geometrica perpendicolare rispetto alla retta e la distanza dall'origine sarà il valore della proiezione

PCA, cerca l'asse di maggior varianza dei dati (l'asse in cui i dati sono più allungati)

L'ASSE MIGLIORE DIPENDE DALL'OBIETTIVO CHE VOGLIAMO RAGGIUNGERE
- Classificazione e ho etichette: LDA
- Mantenere informazione originale: PCA

Se proietti i punti sulla retta PCA (nera), otterrai la rappresentazione più fedele dei dati originali, ma le classi rosse e blu si sovrapporranno notevolmente sulla retta.

Se proietti i punti sulla retta LDA (verde), l'informazione generale di varianza viene persa (la rappresentazione non è fedelissima), ma le classi rosse e blu risulteranno ben separate l'una dall'altra lungo la retta.

- Autovettori e Autovalori: Il segreto della PCA risiede nella decomposizione agli autovalori (Eigenvalue Decomposition) della matrice di covarianza Σ .
 > L'autovettore ϕ_i di Σ (la sua direzione) indica una direzione di variazione nei dati.
 > L'autovalore λ_i associato (il suo scalare) quantifica l'entità di quella variazione (varianza spiegata) lungo la direzione di ϕ_i .
 - Selezione Ottimale: Per massimizzare l'informazione conservata, PCA seleziona i k autovettori che corrispondono ai k autovalori più grandi. Questi autovettori formano le colonne della matrice di proiezione Φ_k .

Principal Component Analysis

- Componenti Principali:
 > Ogni autovettore ϕ_i selezionato è una Componente Principale (PC).
 > La PC con l'autovalore più grande (ϕ_1 , λ_1), direzione di massima varianza) è la prima Componente Principale.
 > Le prime k Componenti Principali sono quelle che conservano la maggior quantità di informazione (varianza) del dataset originale.

(PCA)

Dato un training set $TS = \{\mathbf{x}_i \in \mathbb{R}^d, i = 1 \dots n\}$, siano:

(non abbiamo le etichette: caso non supervisionato)

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1 \dots n} \mathbf{x}_i$$

Il vettore medio in $\mathbb{R}^d$ è semplicemente la media aritmetica di tutti i vettori di dati. È il centroide dei dati e serve come punto di riferimento per la centratura dei dati.

Mi dice come sono disposti i dati rispetto agli assi d

$$\Sigma = \frac{1}{n-1} \sum_{i=1 \dots n} (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^t$$

Moltiplicazione colonna per riga: si crea una matrice (con sommatoria, sommo tante matrici quanti sono i pattern, ognuna di dimensione d)

- Gli elementi sulla diagonale principale σ_{jj} rappresentano la varianza della j -esima dimensione.
- Gli elementi fuori diagonale σ_{jk} rappresentano la covarianza tra la dimensione j e la dimensione k .
- Importanza: sigma descrive la forma, la diffusione e l'orientamento della nuvola di dati.
- Divisione per $n-1$: Come correttamente indicato, la divisione per $n-1$ viene utilizzata per ottenere una stima unbiased della covarianza della popolazione.

il vettore medio $\in \mathbb{R}^d$ e la matrice di covarianza $\in \mathbb{R}^{d \times d}$ (definizioni simili a quelle usate per il classificatore di Bayes parametrico con multinormali. La divisione per $n-1$ invece di n dovuta a correzione di Bessel per caso unbiased).

Determina l'origine dello spazio k dimensionale

allora per un dato k ($k < d, k < n, k > 0$), lo spazio k dimensionale $(S_{\bar{\mathbf{x}}, \Phi_k})$ è univocamente definito dal vettore medio e dalla matrice di proiezione $\Phi_k \in \mathbb{R}^{d \times k}$ le cui colonne sono costituite dagli autovettori di Σ corrispondenti ai k più grandi autovalori:

Ordinato per ordine di importanza (decrescente per autovalore)


$$\Phi_k = [\phi_{i_1}, \phi_{i_2} \dots \phi_{i_k}] \text{ con } \lambda_{i_1} \geq \lambda_{i_2} \geq \dots \lambda_{i_k} \geq \dots \lambda_{i_d}$$

Gli autovalori indicano l'importanza degli autovettori

Gli autovettori più importanti sono quelli che hanno autovalori con modulo massimo

da questi selezioniamo solo i primi k

ϕ_{i_r} autovettore di Σ corrispondente all'autovalore λ_{i_r} , $r = 1 \dots d$



Quello che faccio è trovare i k assi nella direzione di maggior varianza nel TS

ϕ_{i_1} indica la direzione di maggior varianza nel training set TS

I primi k autovettori sono detti componenti principali

Qual'è la proiezione che vogliamo fare? Proiettare i dati sulle componenti principali (autovettori con autovalori di modulo massimo)

La Matrice di Proiezione rimane $d \times k$ perché le sue colonne sono i k autovettori selezionati, che sono vettori nello spazio d -dimensionale originale.

La proiezione è il mapping dal vecchio spazio ad alta dimensione $\mathbb{R}^d$ al nuovo spazio a bassa dimensione $\mathbb{R}^k$.

I punti sono stati spostati prima del calcolo degli autovettori, sottraendo ai pattern la media dei pattern (sposta l'origine del sistema di coordinate dal (0,...,0) al centroide dei dati).


Gli autovettori (colonne di Φ_k) non spostano i punti; definiscono un nuovo sistema di riferimento (una nuova base) all'interno dello stesso spazio $\mathbb{R}^d$.

PCA: proiezione e retroproiezione

Cosa significa, geometricamente, proiettare?

cioè dopo aver calcolato la matrice di proiezione Φ_k e vettore medio, ora possiamo applicarla a qualsiasi nuovo pattern del TS.

Proiezione ($\rightarrow$): una volta determinato lo spazio PCA, la proiezione di un pattern su tale spazio è semplicemente la proiezione geometrica di un vettore sull'iperpiano che definisce lo spazio. In realtà la vera proiezione geometrica è un vettore che ha la stessa dimensionalità del vettore originale mentre in questo contesto indichiamo con proiezione il vettore (ridotto) nello spazio PCA. Matematicamente questa operazione è eseguita come prodotto della matrice di proiezione trasposta per il pattern al quale è preventivamente sottratta la media.




La retroproiezione è il processo inverso: si prende un pattern ridotto nello spazio PCA $\mathbb{R}^k$ e lo si riporta (o ricostruisce) nello spazio originale $\mathbb{R}^d$. Obiettivo: Ottenere una ricostruzione approssimata del vettore originale, dato che la riduzione è lossy. La retroproiezione restituisce il punto che giace sull'iperpiano PCA e che è più vicino al punto originale x .

Retro-proiezione ($\leftarrow$): Dato un vettore nello spazio PCA, la sua retro-proiezione verso lo spazio originale si ottiene moltiplicando il vettore per la matrice di proiezione e sommando il vettore medio. Questa trasformazione non sposta spazialmente il vettore, che giace ancora sullo spazio PCA, ma opera un cambiamento di coordinate che ne permette la codifica in termini delle d componenti dello spazio originale.


Nota Importante: Il vettore ricostruito non è (generalmente) identico al vettore originale x , ma è la sua migliore approssimazione lineare nello spazio definito dalle k Componenti Principali. La differenza tra il vettore originale e quello ricostruito rappresenta l'errore di ricostruzione, che è l'informazione meno rilevante scartata dalla PCA.

Quando abbiamo proiettato, abbiamo perso informazione, quindi da y non possiamo mai tornare ad x (sarà vicino ad x , ma non sarà esattamente x)



La retro-proiezione non ci serve quasi mai a niente

PCA: esempio riduzione 2→1



- L'ellisse rappresenta la distribuzione dei pattern nel training set.
- $\boldsymbol{\varphi}_1$ e $\boldsymbol{\varphi}_2$ sono gli autovettori della matrice di covarianza.
- Gli autovalori λ_1 e λ_2 sono le varianze della distribuzione lungo gli assi $\boldsymbol{\varphi}_1$ e $\boldsymbol{\varphi}_2$.
- y_1 e y_2 sono le proiezioni di $\mathbf{x}$ sugli assi $\boldsymbol{\varphi}_1$ e $\boldsymbol{\varphi}_2$.
- Se λ_2 è piccolo, $\mathbf{x}$ può essere approssimato con $\mathbf{x}'$ (retroproiezione di $\mathbf{y}$) senza perdite significative di informazione.
- Si può dimostrare che tra tutte le riduzioni di dimensionalità lineari PCA è quella che preserva al massimo l'informazione dei vettori originali.

PCA: scelta di k

- Talvolta la scelta di k è obbligata: ad esempio per la visualizzazione 2D o 3D dei dati. k deve essere 2 (per un grafico 2D) o 3 (per un grafico 3D).
- Quando invece l'obiettivo è quello di scartare informazione inutile e dati correlati mantenendo gran parte del contenuto informativo si può scegliere k nel modo seguente:
 - Fissata una percentuale t del contenuto informativo che si vuole preservare (es. $t = 95\%$) si sceglie il minimo valore di k per cui la somma dei più grandi k autovalori, rispetto alla somma di tutti gli autovalori, è maggiore o uguale a t .
 - Considerando gli autovalori ordinati in ordine decrescente:

$$k = \arg \min_z \left\{ \frac{\sum_{i=1 \dots z} \lambda_i}{\sum_{i=1 \dots d} \lambda_i} \geq t \right\}$$

Facendo questa divisione ottengo un valore tra 0 e 1, che indica l'informazione che voglio preservare

Infatti, ricordando che gli autovalori denotano la varianza lungo i diversi assi, il rapporto, nella formula, indica la varianza «conservata» rispetto alla varianza totale.

Questi 8 vettori rappresentano le 8 direzioni più importanti nello spazio dei volti del dataset. Collettivamente, spiegano la maggior parte della varianza (le differenze strutturali e di illuminazione) osservata tra tutti i volti.



rivela quali sono le caratteristiche facciali più significative che l'algoritmo utilizza per codificare, comprimere e, infine, riconoscere i volti.

Esempio grafico

PCA: codifica di un'immagine

Eigenfaces: Sono i "volti medi" o template che catturano le direzioni principali di variazione tra i volti del dataset (ad esempio: forma del naso, posizione degli occhi, ecc.).

i primi 8 autovettori o componenti principali
(denominati eigenfaces nell'applicazione al riconoscimento volto)
autofacce (applicazione PCA nel riconoscimento volti)



Immagine originale



Ricostruzione (retroproiezione)

$$\mathbf{x} \in \mathbb{R}^{16500}$$

numero pixel nella foto

Quindi, ogni pattern è costituito da 16500 dimensioni/features

ogni pixel ha come valore l'intensità di grigio per quel pixel

$$\mathbf{x}' \in \mathbb{R}^{16500}$$

$$\mathbf{y} = \overrightarrow{PCA}(\mathbf{x}, S_{\bar{\mathbf{x}}}, \Phi_{15})$$

Le immagini vengono codificate con soli 15 valori

da 16500 a 15

$$\mathbf{y} \in \mathbb{R}^{15}$$

Tramite PCA, prendiamo i primi 15 autovettori più importanti

$$\mathbf{x}' = \overleftarrow{PCA}(\mathbf{y}, S_{\bar{\mathbf{x}}}, \Phi_{15})$$

proiezione

-2532	2193	-2179	2099	491
427	-324	961	35	-40
-149	-624	317	-158	-142

retro-proiezione

Calcolo PCA in pratica

Per d elevato (tipico nel caso di immagini, audio, ecc.) la matrice di covarianza può essere molto grande.

■ per $d = 16500$, $\Sigma \in \mathbb{R}^{16500 \times 16500}$, oltre 272 milioni di valori !

cioè, il numero di pattern n è molto inferiore alla dimensionalità d

■ se $n \ll d$, è conveniente calcolare la matrice di proiezione (primi k autovettori) attraverso decomposizione SVD della matrice rettangolare dei pattern centralizzati $\mathbf{X} \in \mathbb{R}^{d \times n}$ senza passare per la matrice di covarianza (vedi [1]).

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 - \bar{\mathbf{x}} & \mathbf{x}_2 - \bar{\mathbf{x}} & \cdots & \mathbf{x}_n - \bar{\mathbf{x}} \end{bmatrix}$$

Attenzione

formato trasposto rispetto a $\mathbf{X}$ usata in regressione.
Ogni pattern una colonna.

decomposizione SVD per $d > n$: $\mathbf{X} = \mathbf{U}\mathbf{\Gamma}\mathbf{V}^t$, con $\mathbf{U} \in \mathbb{R}^{d \times n}$ ortonormale, con $\mathbf{V} \in \mathbb{R}^{n \times n}$ ortonormale, $\mathbf{\Gamma} \in \mathbb{R}^{n \times n}$ diagonale.

$$\Sigma = \frac{1}{n} \mathbf{X}\mathbf{X}^t = \frac{1}{n} \mathbf{U}\mathbf{\Gamma}\mathbf{V}^t\mathbf{V}\mathbf{\Gamma}\mathbf{U}^t = \frac{1}{n} \mathbf{U}\mathbf{\Gamma}^2\mathbf{U}^t$$

matrice $\mathbb{R}^{n \times d}$

decomposizione
spettrale della
matrice quadrata Σ

Invece di calcolare la gigantesca Sigma e decomporla, calcoliamo l'SVD della matrice dei dati $\mathbf{X}$ ($d \times n$), ottenendo direttamente la matrice $\mathbf{U}$ che contiene i nostri autovettori, in modo molto più efficiente. Questo è il metodo standard per PCA ad alta dimensionalità.

Autovettori e autovalori di Σ possono dunque essere ottenuti dalle colonne di $\mathbf{U}$ (vettori singolari sinistri di $\mathbf{X}$) e corrispondenti elementi diagonali di $\mathbf{\Gamma}$ al quadrato (valori singolari al quadrato di $\mathbf{X}$).

[1] R. Madsen, L. Hansen, O. Winther, "Singular Value Decomposition and Principal Component Analysis", http://www2.imm.dtu.dk/pubdb/views/edoc_download.php/4000/pdf/imm4000.pdf

Il PCA Whitening è una trasformazione che ha lo scopo di rendere la matrice di covarianza dei dati trasformati una matrice identità. Questo significa che i dati trasformati avranno due proprietà desiderate:

- Decorrelazione: Le features non sono più correlate tra loro (elementi fuori diagonale uguali a zero).
- Varianza Uniforme: Ogni feature ha varianza unitaria (elementi sulla diagonale uguali a uno).

PCA si può applicare anche in casi dove non c'è bisogno di riduzione (PCA Whitening dove $k=d$)

PCA Whitening


È una tecnica di **pre-normalizzazione** dei dati, che:

Fase 1: Decorrelazione

- Rimuove le correlazioni tra le dimensioni, ruotando la nuvola di punti per allineare gli assi di variazione principale dei dati (autovettori) agli assi cartesiani.

Questo primo passaggio corrisponde alla PCA con $k=d$ (cioè, non c'è riduzione dimensionale, solo trasformazione):

- Azione: Rotazione della nuvola di punti in modo che le direzioni di massima variazione (gli autovettori, ϕ_1 e ϕ_2 nell'esempio) siano allineate con gli assi cartesiani standard (x e y).
- Obiettivo: Rimuovere le correlazioni. Nello spazio originale (a sinistra), l'ellissoide indica che le dimensioni sono correlate. Nello spazio trasformato (a destra), le features sono decorrelate. La nuvola di punti è ora orientata orizzontalmente/verticalmente.
- La matrice di covarianza dei dati è ora una matrice diagonale.




Fase 2: Scaling

- Sfericizza l'ellissoide, uniformando le varianze (denotate dagli autovalori) a 1 lungo tutti gli assi

Dopo la decorrelazione, le varianze lungo i nuovi assi sono diverse (date dagli autovalori, $\lambda_{i1} > \lambda_{i2}$). La nuvola di punti è ancora un ellissoide, solo che è allineato agli assi.

- Azione: Scaling (Riscaldamento) lungo ogni dimensione (autovettore) dividendo per la radice quadrata del suo autovalore corrispondente.
- Obiettivo: Uniformare le varianze. Poiché l'autovalore (λ_{i1}) denota la varianza, dividere per la deviazione standard ($\sigma_{i1} = \sqrt{\lambda_{i1}}$) normalizza la varianza a 1 lungo ogni asse.



Dopo aver proiettato i pattern sullo spazio PCA, (definito dai primi k autovettori) è sufficiente dividere ogni dimensione per la radice quadrata dell'autovalore corrispondente (deviazione standard).

Dopo aver applicato PCA Whitening,


✓ La matrice di covarianza dei dati normalizzati è l'identità.

Per uniformare ad 1 le varianze su tutti gli assi, sfericizzando così l'ellissoide (FASE 2 PCA Whitening)

Linear Discriminant Analysis (LDA)

Obiettivo: discriminare al meglio le classi

■ Riduzione di dimensionalità lineare e supervisionata il cui obiettivo è massimizzare la separazione tra le classi (che nel TS sono etichettate). L'esempio seguente mostra che al fine della discriminazione la soluzione ottimale può essere anche molto diversa dalla soluzione PCA.



Come si fa a trovare l'asse rossa, quindi la matrice di proiezione? Dobbiamo trovare la matrice perché alla fine si moltiplica il vettore del data point nella dimensione originale con la matrice di proiezione e si ottiene il vettore ridotto

Per formalizzare matematicamente l'obiettivo di separazione, l'LDA definisce due "Matrici di Scatter", che sono l'equivalente non normalizzato delle matrici di covarianza.

- 1. Matrice di Scatter Intra-Classe: misura quanto i singoli vettori di dati sono sparpagliati rispetto al proprio centroide di classe (media).
- > Obiettivo di LDA: L'LDA cerca di minimizzare questa dispersione, rendendo i cluster di classe più compatti possibile.
- 2. Matrice di Scatter Inter-Classe: misura quanto i centri delle diverse classi (μ_i) sono dispersi rispetto al centro generale (bar{x}) di tutti i pattern.
- > Obiettivo di LDA: L'LDA cerca di massimizzare questa dispersione, allontanando il più possibile le medie delle classi.

■ Per formulare il criterio di ottimizzazione di massima separazione tra le classi sono definite le seguenti **matrici di scattering** (in italiano "sparpagliamento"):

1 ■ Le proiezioni di vettori dentro le classi devono essere il più vicino possibile tra di loro

1 ■ **within-class** S_w : indica come i vettori sono scattered rispetto al centro delle classi (ciascuno rispetto alla propria classe).

2 ■ Le proiezioni di vettori di differenti classi devono essere il più lontano possibile tra di loro

2 ■ **between-class** S_b : indica come i centri delle classi sono scattered rispetto al centro generale della distribuzione (ovvero quanto le classi sono scattered).

Quindi, minimizzare lo scattering intra-classe e massimizzare lo scattering inter-classe

Una Matrice di Scatter è la somma degli scarti quadratici dei pattern, mentre la Matrice di Covarianza è la media degli scarti quadratici dei pattern.

Una matrice di scatter si calcola come una matrice di covarianza senza normalizzare per il numero di pattern

Calcolo LDA

Dato un training set **TS** contenente n pattern $(\mathbf{x}_1, y_1) \dots (\mathbf{x}_n, y_n)$, dove $\mathbf{x}_i \in \mathbb{R}^d$ sono i pattern multidimensionali e $y_i \in [1 \dots s]$ le etichette delle s classi. Siano n_i e $\bar{\mathbf{x}}_i$ il numero di pattern e il vettore medio della classe i -esima. Allora le matrici di scattering sono definite come:

Matrice di Scatter Intra-Classe

within-class:

$$\mathbf{S}_w = \sum_{i=1 \dots s} \mathbf{S}_i$$

è la dispersione (scatter) dei punti della singola classe i rispetto al centroide della classe i .

$$\mathbf{S}_i = \sum_{j=1}^{n_i} (\mathbf{x}_j - \bar{\mathbf{x}}_i)(\mathbf{x}_j - \bar{\mathbf{x}}_i)^t$$

La matrice $\mathbf{S}_i$ indica la somma degli scarti quadratici dei pattern appartenenti alla classe i rispetto alla media (centroide) di quella specifica classe i .

pattern della classe i - esima

Matrice di Scatter Inter-Classe

between-class:

$$\mathbf{S}_b = \sum_{i=1 \dots s} n_i \cdot (\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_0)(\bar{\mathbf{x}}_i - \bar{\mathbf{x}}_0)^t$$

$$\bar{\mathbf{x}}_0 = \frac{1}{n} \sum_{i=1 \dots s} n_i \cdot \bar{\mathbf{x}}_i$$

Media pesata (numero di pattern di ciascuna classe) dei centroidi

media globale

Tra i diversi criteri di ottimizzazione possibili quello più frequentemente utilizzato è la **massimizzazione** della quantità:

Rapporto tra le due matrici di scattering intra e inter

$$J_1 = \text{tr}(\mathbf{S}_w^{-1} \mathbf{S}_b) = \sum_{i=1 \dots d} \lambda_i$$

dove tr è la **traccia** (somma degli autovalori) della matrice. Il criterio è **intuitivo** in quanto cerca di massimizzare lo scattering tra le classi ($\mathbf{S}_b$) minimizzando al contempo (matrice inversa $\mathbf{S}_w^{-1}$) quello all'interno di ogni classe.

Si dimostra che per la massimizzazione di J_1 , lo spazio LDA è definito (*analogia con PCA*) dagli autovettori relativi ai primi k ($k < n, k < s, k < d$) autovalori della matrice $\mathbf{S}_w^{-1} \mathbf{S}_b$.



valore massimo di $k = s - 1$

La limitazione deriva dalla natura della matrice di dispersione between-class: $\mathbf{S}_b$ è costruita dalle differenze tra gli s centroidi di classe. Geometricamente, tutti gli s centroidi si trovano al massimo in un sottospazio $(s-1)$ -dimensionale. Pertanto, la matrice $\mathbf{S}_b$ ha un rango massimo di $s-1$.


t-distributed Stochastic Neighbor

Embedding (t-SNE)

Dopo aver addestrato il sistema, vengono mostrate in 2D/3D le classi del training set

Algoritmo iterativo

- È una **tecnica non lineare** (**non supervisionata**) per la riduzione di dimensionalità introdotta nel 2008 da Van der Maaten e Hinton [1].
- **Rappresenta** (insieme a UMAP) **lo stato dell'arte per la visualizzazione 2D o 3D di dati multidimensionali**. Implementazione disponibile in molti linguaggi in [2].
- **Anche PCA** (con $k = 2$ o $k = 3$) **può essere utilizzata a tale scopo**, **ma dati con distribuzioni spiccatamente non multinormali non possono essere efficacemente «ridotti» attraverso un mapping lineare**.
- **Esempio**: visualizzazione 2D di MNIST (digit scritti a mano).



[1] L.J.P. van der Maaten and G.E. Hinton. Visualizing High-Dimensional Data Using t-SNE. *Journal of Machine Learning Research*, 2008.


[2] <https://lvdmaaten.github.io/tsne/>

t-SNE in sklearn

dataset utilizzato nella
competition DogsVsCat

- **Esempio:** visualizzazione 2D di un dataset contenente immagini (non controllate) di 1000 Cani + 1000 Gatti, utilizzando come feature di input le HOG (Histogram of Oriented Gradients) invece dei pixel.

```
from sklearn.manifold import TSNE
tsne = TSNE(n_components=2, perplexity=30.0, n_iter=1500,
            init='random', random_state=1, verbose=2)
X_embedded_hog = tsne.fit_transform(hog_features_x)
plt.scatter(X_embedded_hog[0:1000, 0], X_embedded_hog[0:1000, 1], c="r")
plt.scatter(X_embedded_hog[1000:2000, 0], X_embedded_hog[1000:2000, 1], c="g")
plt.show()
print(X_embedded_hog.shape)
```



Se usiamo le Hog Features, il Problema (DogsVsCat) risulta molto difficile da risolvere

I due cluster sono molto sovrapposti. I classificatori tradizionali (es. SVM) raggiungono il 70% circa, sfruttando la maggiore densità dei pattern verdi (gatti) in una certa regione.


Facendolo direttamente sui Pixel anziché sulle Hog, non migliora (oltre a richiedere più potenza computazionale)

- Vedi <https://distill.pub/2016/misread-tsne/> per consigli su come tarare i parametri (es. perplexity) di t-SNE.

UMAP preserva le relazioni locali all'interno dei cluster e fornisce anche una rappresentazione più fedele delle relazioni globali tra cluster, mentre t-SNE è limitato alla sola struttura locale.

UMAP

- **UMAP [1] (Uniform Manifold Approximation and Projection for Dimension Reduction)** è una tecnica di riduzione di dimensionalità (non lineare e non supervisionata) simile a t-SNE, utile per la visualizzazione 2D o 3D di dati multidimensionali.
- Come t-SNE anche UMAP preserva le distanze locali ed è in grado di individuare cluster di dati localmente connessi.
 - ↳ Mantiene Struttura Globale e Locale (le distanze tra i cluster sono più fedeli).
- UMAP ha maggiore capacità di preservare (anche) la struttura globale dei cluster. In altre parole, t-SNE può visualizzare cluster vicini o lontani indipendentemente dalla loro similarità nello spazio originale, mentre UMAP preserva meglio anche le distanze inter-cluster.



sud-america tra africa e nord-america?

[N. Oskolkov, 2020]

- Codice e Documentazione: [link](#).

[1] McInnes, L, Healy, J, UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction, ArXiv e-prints 1802.03426, 2018.